

## Entrega 1

Juan Sebastian Fajardo Zarta  
Andres Felipe Parra Barragan

### 1. Contexto de aplicación

La movilidad en áreas urbanas se enfrenta a desafíos complejos, como el aumento del tráfico y la necesidad de una gestión más eficiente de las vías para garantizar una circulación fluida y segura. Este proyecto se centra en la detección y seguimiento de objetos en imágenes obtenidas de cámaras de tráfico, con el objetivo de crear un sistema automatizado que permita identificar vehículos, peatones y señales de tráfico. Esta solución puede ser crucial en la mejora de la gestión del tráfico, la prevención de accidentes, y la planificación urbana, así como en la implementación de sistemas de gestión de tráfico basados en inteligencia artificial, contribuyendo al desarrollo de ciudades inteligentes.

### 2. Objetivo de machine learning

El objetivo principal de machine learning de este proyecto es la detección y seguimiento de objetos dentro de imágenes capturadas por cámaras de tráfico. Queremos identificar vehículos, peatones y señales de tráfico en diferentes condiciones climáticas e iluminación; para posteriormente, analizar el tráfico y predecir situaciones de congestión. Este enfoque busca desarrollar un modelo que, a partir de una imagen de tráfico, pueda detectar objetos de interés, y utilizar esta información para inferir la densidad del tráfico y anticipar posibles congestiones, proporcionando una herramienta valiosa para mejorar la planificación y gestión urbana.

### 3. Dataset [1]

- **Tipo de datos:** Imágenes de cámaras de tráfico (640 x 640 píxeles), con anotaciones que incluyen cuadros delimitadores para la identificación de objetos (vehículos, peatones y señales de tráfico).
- **Tamaño:** El dataset consta de 6500 imágenes de 640 x 640 píxeles cada una. El tamaño total del dataset en disco es de aproximadamente 1.2 GB.
- **Distribución de las clases:** Cada imagen incluye múltiples anotaciones que identifican vehículos, peatones y señales de tráfico. Cada imagen puede tener una cantidad variable de cada clase, lo cual permite modelar un escenario complejo de tráfico urbano. Consideramos a los vehículos como la clase dominante.

### 4. Métricas de desempeño

- **Métricas de machine learning:**
  - **Precision:** Esta métrica mide cuántas de las predicciones positivas del modelo son correctas. Entonces en este caso, la precisión medirá la detección de los objetos dentro de las imágenes, considerando las diferentes clases; para ello, es útil minimizar los falsos positivos [2].

- **IOU:** Calcula la superposición entre el bounding box predicho y el real, midiendo cuán bien el modelo delimita el objeto correcto. IOU es fundamental en este proyecto, ya que queremos que los cuadros delimitadores se ajusten de la mejor manera posible a los objetos reales.
- **Recall:** Medirá la capacidad del modelo para identificar la mayor cantidad posible de objetos presentes en las imágenes.
- **F1-score:** Es la media entre Precision y Recall. Esta métrica es útil cuando se necesita un balance entre la capacidad del modelo de encontrar todos los objetos (Recall) y de ser preciso en las detecciones (Precision) [3]. En la gestión del tráfico, F1-score ayuda a evaluar si el modelo detecta la mayoría de los objetos sin generar demasiados falsos positivos.
- **Mean Average Precision (mAP):** Es una métrica comúnmente utilizada para evaluar el rendimiento de los modelos de detección de objetos. Calcula el promedio de la precisión en todas las clases y se utiliza para medir la capacidad del modelo de detectar correctamente varios tipos de objetos. Es útil con múltiples categorías, como en este caso con vehículos, peatones, y señales de tráfico [4].

- **Métricas de negocio:**

- **Reducción de Accidentes**

Métrica de Negocio: Cuantificar cuántos accidentes se han reducido en un período de tiempo después de implementar el modelo. Esto podría traducirse en menos congestión y menos costos relacionados con daños o interrupciones en el flujo de tráfico.

Impacto: Un sistema de detección temprana de comportamientos riesgosos (como vehículos en contravía o violaciones de semáforos) podría ayudar a reducir la probabilidad de accidentes

- **Optimización del Flujo Vehicular**

Métrica de Negocio: Medir el aumento en la velocidad promedio del tráfico en rutas monitoreadas o la reducción en el tiempo de viaje después de la implementación del modelo.

Impacto: Un modelo que predice y gestiona patrones de congestión en tiempo real podría permitir que los sistemas de tráfico ajusten automáticamente los semáforos o desvíe el tráfico, optimizando el flujo vehicular.

- **Mejora en la Planificación Urbana**

Métrica de Negocio: Analizar cómo el sistema contribuye a una mejor toma de decisiones en la planificación de nuevas rutas o mejoras en la infraestructura urbana.

Impacto: Los datos proporcionados por un sistema de predicción de tráfico pueden ofrecer insights para ajustar la infraestructura según los patrones de congestión, optimizando el diseño de calles, puentes o redes de transporte público.

- **Tiempo de Respuesta ante Incidentes**

Métrica de Negocio: Evaluar la rapidez con la que se responde a incidentes detectados a través de imágenes, como atascos, accidentes o infracciones.

Impacto: Un modelo eficiente de predicción de tráfico permite alertar rápidamente a las autoridades sobre eventos críticos, mejorando la intervención temprana y reduciendo tiempos de inactividad en el tráfico.

## **5. Resultados previos**

- Estudios anteriores han demostrado que modelos de deep learning, como YOLO y Faster R-CNN, son efectivos en tareas de detección de objetos en escenarios de tráfico, alcanzando precisiones de detección superiores al 70% en condiciones similares [5, 6]. Estos trabajos previos sugieren que la combinación de técnicas de detección de objetos con análisis predictivo del tráfico puede proporcionar un sistema robusto para la gestión del tráfico urbano.

## **6. Referencias**

[1]

<https://www.kaggle.com/datasets/yusufberksardoan/traffic-detection-project/data?select=valid>

[2] <https://databitai.com/machine-learning/metricas-de-evaluacion-en-machine-learning/>

[3] <https://sitiobigdata.com/2019/01/19/machine-learning-metrica-clasificacion-parte-3/>

[4]

<https://www.datasource.ai/es/data-science-articles/metricas-de-evaluacion-de-modelos-en-el-aprendizaje-automatico>

[5] <https://arxiv.org/abs/1506.01497>

[6] <https://www.v7labs.com/blog/yolo-object-detection>